

■ PROJET TECHCORP — Challenge IA 7h

■ Briefing de Mission

Contexte : Vous êtes la nouvelle équipe technique de TechCorp Industries. L'équipe précédente a été licenciée suite à des soupçons de compromission du code et des données. Vous devez reprendre leur travail, valider l'intégrité du projet et finaliser le déploiement.

■ Objectifs Principaux

■ Mission Critique — Production Ready

Déployer le modèle **Phi-3.5-Financial** avec une interface chat :

- Serveur d'inférence opérationnel avec Phi-3.5-Financial — au choix de votre équipe :
- **Ollama** (solution clé en main recommandée)
- **Triton Inference Server** (solution avancée, configuration fournie)
- **Serveur maison** (FastAPI, Flask, vLLM... tout ce qui expose une API)
- Interface web **obligatoire** pour interagir avec le modèle en temps réel
- Documentation technique de votre déploiement

■ Mission Expérimentale — R&D;

Fine-tuner un modèle médical expérimental (pas pour production) :

- Fine-tuning LoRA d'un modèle de base avec dataset médical fourni
- Tests et validation des performances conversationnelles
- *Note : Ce modèle reste expérimental, pas besoin de le déployer en production*

■ Ressources à Disposition

■ Infrastructure Technique

- **Ollama** — Serveur d'inférence local, solution la plus simple (ollama.com/download)
- **Triton Inference Server** — Déploiement avancé, configuration fournie dans `triton_server/`
- **Serveur maison** — FastAPI, vLLM, llama.cpp... tout ce qui expose une API REST
- **Phi-3.5-Financial** — Modèle spécialisé finance/business, prêt à l'emploi (voir `models/phi3_financial/`)
- **Dataset médical** — Pour fine-tuning expérimental
- **Google Colab Pro** — GPU pour fine-tuning et tests

■ Fichiers Hérités de l'Équipe Précédente

- Code d'entraînement et de fine-tuning LoRA pour le modèle financier
- Modèle Phi-3.5-Financial pré-entraîné
- Code pour un chatbot de base
- Quelques configurations de serveurs d'inférence (Ollama, Triton, etc.)
- Dataset de conversations médicales (format JSON)
- Documentation technique partielle
- *Quelques fichiers de logs et notes personnelles laissés sur les machines*

■ Pistes Techniques

- **Quantization** : Envisagez des modèles quantisés (4-bit/8-bit) pour optimiser les performances
- **Backend Python** : Triton supporte un backend Python plus simple que TensorRT
- **Modèles alternatifs légers** : phi3.5, qwen2.5:3b, mistral, tinyllama

■ Répartition des Rôles par Filière

■ INFRA — L'Architecte du Système

Mission :

- Choisir et déployer un serveur d'inférence avec Phi-3.5-Financial (Ollama / Triton / Serveur maison)
- Rendre le serveur accessible à l'équipe DEV WEB (URL + port)
- Optimiser les performances (paramètres d'inférence, quantization)

Livrables :

- Serveur d'inférence opérationnel avec Phi-3.5-Financial
- Documentation de déploiement (choix technique justifié)

■ IA — Le Spécialiste Modèles

Mission :

- Validation et tests du modèle Phi-3.5-Financial
- Optimisation des paramètres d'inférence
- Fine-tuning LoRA d'un modèle médical avec le dataset fourni
- Tests de performance du modèle expérimental

Livrables :

- Modèle Phi-3.5-Financial validé et optimisé
- Modèle médical expérimental fine-tuné (LoRA)

■ DATA — L'Expert Données

Mission :

- Validation des données d'entrée pour Phi-3.5-Financial
- Tests de qualité des conversations
- Analyse et nettoyage du dataset médical
- Préparation des données pour le fine-tuning LoRA
- Validation de la qualité des conversations médicales

Livrables :

- Dataset médical préparé et nettoyé
- Rapport de qualité des données

■ CYBER — Le Responsable Sécurité

Mission :

- Audit de sécurité du déploiement (Ollama, Triton, ou serveur maison)
- Tests de robustesse du modèle Phi-3.5-Financial
- Validation de l'intégrité des réponses
- Tests de sécurité du modèle médical fine-tuné
- Vérification de l'absence de biais problématiques

Livrables :

- Tests de robustesse validés

■ DEV WEB — Le Développeur Interface

Mission :

- Développer une interface web de chat (obligatoire)
- Intégrer l'API du serveur d'inférence choisi par l'équipe INFRA
- Ollama : <http://localhost:11434>
- Triton : <http://localhost:8000>
- Serveur maison : URL communiquée par l'équipe INFRA
- Interface utilisateur intuitive pour tester le modèle

Livrables :

- Interface web complète et fonctionnelle
- Intégration API temps réel avec le serveur d'inférence de l'équipe

■ Architecture du Projet

```
techcorp-ai-chat/  
■■■ triton_server/ # Configuration Triton Inference Server  
■■■ models/ # Modèle Phi-3.5-Financial  
■■■ medical_dataset/ # Dataset pour fine-tuning médical expérimental  
■■■ scripts/ # Scripts d'entraînement et de tests
```

■ Documentation & Ressources Utiles

- **Déploiement rapide HuggingFace avec Triton** : github.com/triton-inference-server/tutorials
- **Dataset Médical** : huggingface.co/datasets/ruslanmv/ai-medical-chatbot

■ Mission Finale

Votre objectif principal : Rendre le modèle **Phi-3.5-Financial** accessible via une **interface chat professionnelle** — peu importe le serveur d'inférence choisi (Ollama, Triton, ou maison), l'interface est **non négociable**. N'oubliez pas d'expérimenter sur le fine-tuning du modèle médical.

TechCorp compte sur vous pour finaliser ce projet. Explorez les fichiers laissés par l'équipe précédente, ils peuvent contenir des informations utiles !